Implementación de un Pipeline de datos para el análisis del proceso de contratación en una empresa

Valeria Jiménez Bedoya

Ingeniería de Datos e Inteligencia Artificial
Universidad Autónoma de Occidente

Septiembre 4, 2026

1 Contexto

2 Metodología

3 Resultados

Escenario planteado

- Una empresa de reclutamiento tecnológico busca mejorar su comprensión de sus procesos de selección de candidatos.
- La empresa recibe miles de solicitudes de candidatos con diferentes perfiles profesionales, niveles de experiencia, países, antigüedad y perfiles tecnológicos
- Se evalúa: Puntuación en la prueba de programación y Puntuación en la entrevista técnica

Escenario planteado

- Una empresa de reclutamiento tecnológico busca mejorar su comprensión de sus procesos de selección de candidatos.
- La empresa recibe miles de solicitudes de candidatos con diferentes perfiles profesionales, niveles de experiencia, países, antigüedad y perfiles tecnológicos
- Se evalúa: Puntuación en la prueba de programación y Puntuación en la entrevista técnica

Escenario planteado

- Una empresa de reclutamiento tecnológico busca mejorar su comprensión de sus procesos de selección de candidatos.
- La empresa recibe miles de solicitudes de candidatos con diferentes perfiles profesionales, niveles de experiencia, países, antigüedad y perfiles tecnológicos
- Se evalúa: Puntuación en la prueba de programación y Puntuación en la entrevista técnica

1 Contexto

2 Metodología
- Conjunto de Datos
- Modelo de Datos Dimensional
- ETL

3 Resultados

Arquitectura propuesta

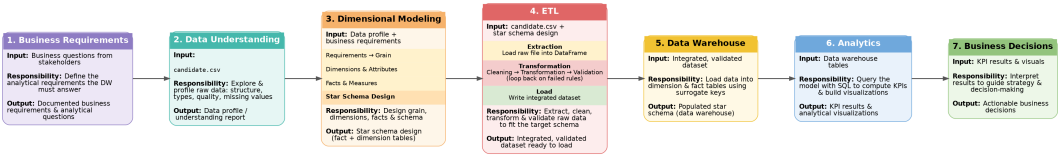


Figure 1: Arquitectura propuesta para la implementación del pipeline de datos

1 Contexto

2 Metodología
- Conjunto de Datos
- Modelo de Datos Dimensional
- ETL

3 Resultados

Conjunto de Datos

- El conjunto contiene aproximadamente 50,000 aplicaciones.

Variable	Descripción
First Name	Nombre del candidato
Last Name	Apellido del candidato
Email	Correo electrónico del candidato
Country	País de residencia del candidato
Application Date	Fecha de aplicación
YOE	Años de experiencia laboral
Seniority	Nivel de seniority del candidato
Technology	Tecnología asociada a la aplicación
Code Challenge Score	Puntaje obtenido en el desafío de código
Technical Interview Score	Puntaje obtenido en la entrevista técnica

Table 1: Variables disponibles en el conjunto de datos.

1 Contexto

2 Metodología
- Conjunto de Datos
- Modelo de Datos Dimensional
- ETL

3 Resultados

Paso 1 – Requerimientos

Requerimiento	Análisis	Variables
1. Tendencias de contratación	Monitorear la evolución de los resultados de contratación a lo largo del tiempo.	Fecha, Is_Hired
2. Análisis tecnológico	Comparar los resultados de contratación entre tecnologías para identificar cuáles presentan mayor cantidad y proporción de candidatos contratados.	Technology, Is_Hired
3. Perfil del candidato	Analizar los resultados de contratación según los años de experiencia y el nivel de seniority.	YOE, Seniority
4. Desempeño técnico	Analizar el desempeño en las evaluaciones técnicas según los años de experiencia y el país del candidato.	Code Challenge, Technical Interview, YOE, Country
5. Brechas entre evaluaciones	Identificar diferencias relevantes entre el desempeño obtenido en el Code Challenge y la Technical Interview.	Code Challenge, Technical Interview
6. Género estimado (Plus)	Analizar tendencias y proporciones de contratación según el género estimado a partir del nombre del candidato.	Género estimado, Is_Hired

Table 2: Requerimientos de análisis para el modelo dimensional.

Paso 2 – Granularidad

Grano de la tabla de hechos

Cada fila de **FactApplication** representa una aplicación de un candidato al proceso de selección para una **tecnología determinada**, registrada en una **fecha de aplicación**, incluyendo sus **años de experiencia profesional, nivel de seniority, resultados obtenidos en el Code Challenge y Technical Interview, género estimado y resultado final de contratación** (is_hired)

Paso 3 – Identificar las Dimensiones

Dimensión	Pregunta de negocio soportada	Atributos principales
DimDate	¿Cuáles son las tendencias de contratación a través del tiempo?	`date_id`, `year`, `month`, `day`
DimTechnology	¿Cuáles son las tecnologías que generan la mayor cantidad y proporción de candidatos contratados?	`technology_key`, `technology_name`
DimSeniority	¿Cómo varían los resultados de contratación según el nivel de seniority?	`seniority_key`, `nivel_seniority`
DimCountry	¿Cuáles son las diferencias en los resultados de contratación y desempeño entre países?	`country_key`, `country_name`

Table 3: Dimensiones identificadas a partir de los requerimientos de negocio.

Paso 4 – Identificar Facts

Medida	Significado	Fuente / Cálculo
code_challenge_score	Desempeño técnico obtenido por el candidato en el Code Challenge.	Valor original de Code Challenge Score.
technical_interview_score	Desempeño técnico obtenido por el candidato en la entrevista técnica.	Valor original de Technical Interview Score.
is_hired	Indica si el candidato fue contratado o no.	1 si ambos puntajes ≥ 7; 0 en caso contrario.
score_gap	Diferencia entre el desempeño obtenido en las dos evaluaciones técnicas.	

Table 4: Medidas y métricas definidas para la tabla de hechos.

Paso 5 – Diagrama Estrella



Figure 2: Diagrama estrella propuesto a partir de los requerimientos del negocio

Paso 6 – Validar el Modelo contra los Requisitos

Requisito	Dimensiones necesarias	Medidas necesarias	¿Es soportada?
R1	DimDate	cantidad_contrataciones	SÍ
R2	DimTechnology	cantidad_contrataciones, proporcion_contratados	SÍ
R3	DimSeniority, DimCandidate	cantidad_contrataciones	SÍ
R4	DimCountry, DimCandidate	code_challenge_score, technical_interview_score	SÍ
R5	DimCandidate	score_gap	SÍ

Table 5: Validación del modelo dimensional frente a los requerimientos de negocio.

1 Contexto

2 Metodología
- Conjunto de Datos
- Modelo de Datos Dimensional
- ETL

3 Resultados

Arquitectura propuesta de ETL

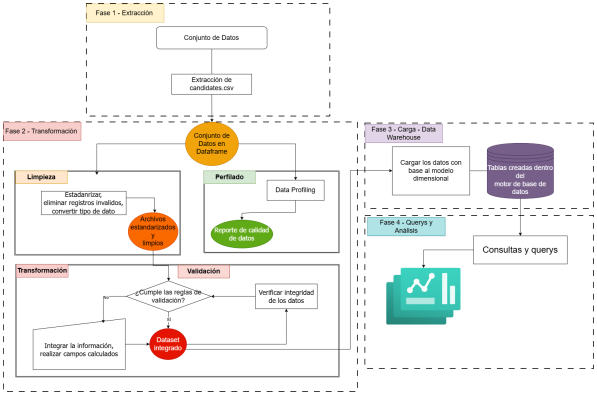


Figure 3: Arquitectura propuesta de etl

Perfilamiento de Datos

Aspecto	Resultado
Número de filas y columnas	50000 filas × 10 columnas
Tipos de datos	3 numéricas y 7 categóricas
Valores faltantes	0 valores faltantes
Registros duplicados	0 registros duplicados
Valores únicos en atributos categóricos relevantes	Country: 244; Seniority: 7; Technology: 24
Fecha mínima de aplicación	2018-01-01
Fecha máxima de aplicación	2022-07-04
Rango de puntajes	Code Challenge: 0–10; Technical Interview: 0–10

Table 6: Resultados del perfilamiento inicial de los datos.

Limpieza de Datos

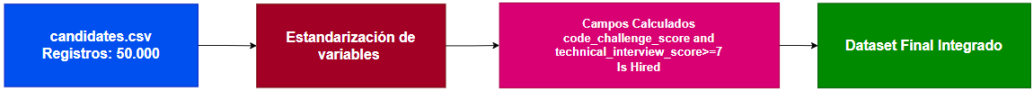


Figure 4: Proceso de procesamiento de los datos.

- Se convierte a mayúsculas las variables tipo caracter.
- Se calcula el campo is_hired
- **Resultado final: 50.000 candidatos(11 columnas).**

Principales Decisiones de Transformación

Decisión	Justificación
Fecha de aplicación: String → DateTime	Se estandarizó el formato de fecha para facilitar el análisis temporal y las agregaciones de la dimensión fecha.
Regla de negocio `IS_HIRED`	Se definió como contratado cuando `code_challenge_score` $\geq$ 7 **y** `technical_interview_score` $\geq$ 7.
Candidate_id	Se implementó un candidate_id para el manejo de correos duplicados
Métricas derivadas	La cantidad de candidatos se obtiene mediante `COUNT(*)` y las contrataciones mediante `SUM(is_hired)`. La tasa de contratación se deriva de estos resultados.
Claves sustitutas (Surrogate Keys)	Se utilizaron claves enteras autoincrementales (`INT`) en las dimensiones para establecer relaciones eficientes mediante claves foráneas.
Cálculo de *Score Gap*	Se generó en la base de datos como `technical_interview_score - code_challenge_score` para analizar las diferencias de desempeño.
Manejo de duplicados	Se utilizó `INSERT IGNORE` para evitar registros duplicados en las dimensiones durante la carga de la tabla de hechos.

Table 7: Principales decisiones tomadas durante el proceso de transformación.

1 Contexto

2 Metodología

3 Resultados

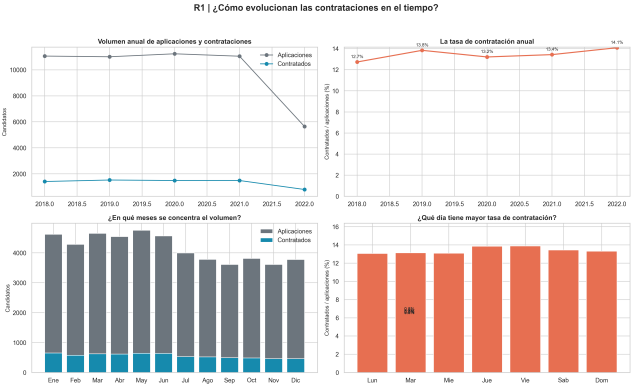
Resultados: Tendencias de Contratación en el Tiempo (R1)

Objetivo

Monitorear la evolución de las contrataciones a través del tiempo.

Métricas

- Total de aplicaciones.
- Cantidad de contrataciones.
- Tasa de contratación (%).
- Evolución por año, mes y día.



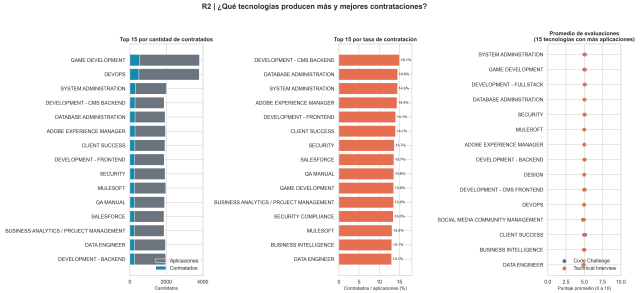
Resultados: Análisis por Tecnología (R2)

Objetivo

Identificar qué perfiles tecnológicos presentan mayor volumen y tasa de contratación.

Métricas

- Cantidad de candidatos.
- Cantidad de contratados.
- Tasa de contratación (%).
- Promedio de Code Challenge.
- Promedio de Technical Interview.



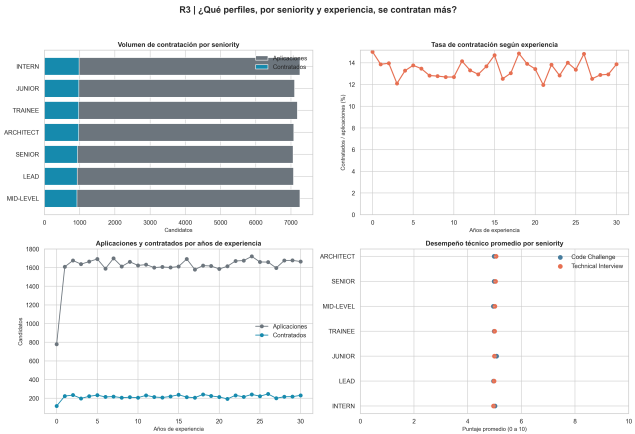
Resultados: Seniority y Años de Experiencia (R3)

Objetivo

Analizar los resultados de contratación según el nivel de seniority y los años de experiencia.

Métricas

- Contrataciones por seniority.
- Contrataciones por años de experiencia.
- Tasa de contratación (%).
- Promedio de desempeño técnico.



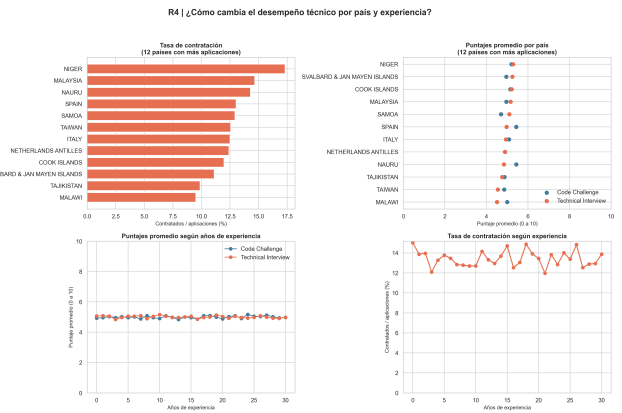
Resultados: Desempeño por País y Experiencia (R4)

Objetivo

Analizar el desempeño técnico de los candidatos según país y años de experiencia.

Métricas

- Promedio de Code Challenge.
- Promedio de Technical Interview.
- Comparación por país.
- Comparación por experiencia.
- Tasa de contratación (%).



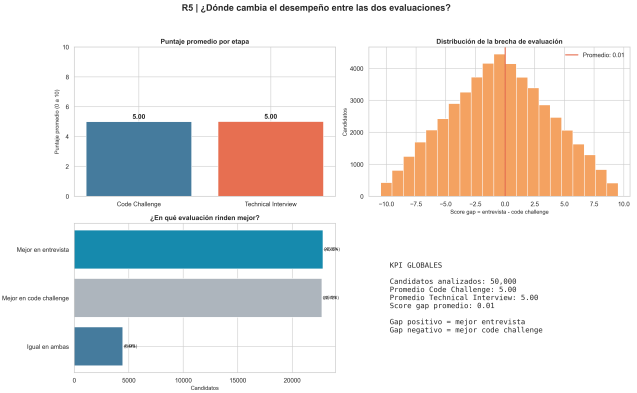
Resultados: Diferencia entre Evaluaciones (R5)

Objetivo

Identificar diferencias relevantes entre el desempeño en el Code Challenge y la Technical Interview.

Métricas

- Promedio de cada evaluación.
- Distribución del *score gap*.
- Candidatos con mejor desempeño en cada evaluación.
- Proporción de cada categoría.



Gracias